

第一章 随机事件间的关系及其运算

名称	记号	含义
包含	$A \subset B$	A 发生 \rightarrow B 发生
相等	$A=B$	A 发生 \leftrightarrow B 发生
和(并)事件	$A \cup B$	A, B 至少有一个发生
积(交)事件	$A \cap B$	A, B 同时发生
差事件	$A - B$	A 发生, B 不发生
A, B 互不相容(互斥)	$A \cap B = \Phi$	A, B 不能同时发生
A 的逆事件(对立)	\bar{A}	A 不发生

A 与 \bar{A} 必有一个发生且仅有一个发生

概率的性质

1) $P(\Phi)=0$

2) A_1, A_2, \dots, A_n 两两不相容 $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$

3) 减法公式 $P(A-B) = P(A) - P(AB)$

特别: $B \subset A \rightarrow P(A-B) = P(A) - P(B)$

单调性: $B \subset A \rightarrow P(B) \leq P(A)$

4) 对任一事件 A , $P(A) \leq 1$

5) 对任一事件 A , $P(\bar{A}) = 1 - P(A)$

6) 加法公式 $P(A \cup B) = P(A) + P(B) - P(AB)$

推广 $P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC)$

古典概型 $P(A) = \frac{k}{n} = \frac{A \text{ 包含的基本事件总数}}{S \text{ 包含的基本事件总数}}$

条件概率 $P(A | B) = \frac{P(AB)}{P(B)}, \quad P(B) > 0$

乘法定理 $P(AB) = P(B|A)P(A)$

全概率公式 $P(A) = \sum_{i=1}^n P(B_i)P(A|B_i)$

Bayes公式 $P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}, i = 1, 2, \dots, n$

A 与 B 相互独立 $P(AB) = P(A)P(B)$ 或 $P(B|A) = P(B)$

- 设事件 A_1, A_2, \dots, A_n 相互独立, 则

$$P(A_1 \cup A_2 \cup \dots \cup A_n) = 1 - P(\bar{A}_1)P(\bar{A}_2) \cdots P(\bar{A}_n)$$

典型例题：

(1) 抽样检验（有放回与不放回）

(2) 抽签问题（一次抽一个不放回，第几次“中奖”的概率都是相同的——公平性）

(3) 全概率与贝叶斯公式应用

例. 设有两个盒子，第一个盒子中放有2个红球及4个白球，第二个盒子中放有3个红球及3个白球。现在任取一个盒子，再从中任取一个球，问：

(1) 取出红球的概率是多少？（全概率公式）

(2) 若知取出的是红球，问它来自哪个盒子的可能性大？（贝叶斯公式）

(4) 事件的独立性

例. 一射手向同一目标独立地进行四次射击，若至少命中一次的概率为 $\frac{80}{81}$ ，试求：该射手进行一次射击的命中率。

第二章 离散型随机变量

分布律: $P(X = x_k) = p_k, k = 1, 2, \dots$

常见: $X \sim (0, 1), X \sim B(n, p), X \sim P(\lambda)$

连续型随机变量

求未知参数

概率密度: $F(x) = \int_{-\infty}^x f(t)dt, f(x) \geq 0, \int_{-\infty}^{\infty} f(x)dx = 1$

常见: $X \sim U(a, b), X \sim \text{Exp}(\theta), X \sim N(\mu, \sigma^2)$

设 $X \sim N(\mu, \sigma^2)$, $i) P\{X \leq x\} = \Phi\left(\frac{x - \mu}{\sigma}\right)$

$ii) P\{x_1 < X \leq x_2\} = \Phi\left(\frac{x_2 - \mu}{\sigma}\right) - \Phi\left(\frac{x_1 - \mu}{\sigma}\right)$

$iii) P\{|X - \mu| < x\} = 2\Phi\left(\frac{x}{\sigma}\right) - 1$

$iv) P\{X > \mu\} = P\{X < \mu\} = 0.5$

一维随机变量的分布函数

$$F(x) = P(X \leq x)$$

作用: $P(x_1 < X \leq x_2) = F(x_2) - F(x_1)$

$$P\{X > x\} = 1 - F(x)$$

$$P\{X = x\} = F(x) - F(x^-)$$

性质1 $F(x)$ 是一个单调非减函数。

性质2 $0 \leq F(x) \leq 1$, $F(-\infty) = 0$, $F(+\infty) = 1$

性质3 $F(x)$ 是右连续的函数。

随机变量的函数的分布

离散型——易于计算

连续型——分布函数法（基本方法）

特别，若 $g(x)$ 在区间 I 上严格单调且可导；
则 $Y = g(X)$ 的密度为： (α, β) 为 Y 的取值范围

$$f_Y(y) = \begin{cases} f_X(h(y)) \cdot |h'(y)|, & y \in (\alpha, \beta), \\ 0, & y \notin (\alpha, \beta). \end{cases}$$

结论

$$X \sim N(\mu, \sigma^2), \quad Y = aX + b$$

$$\rightarrow Y \sim N(a\mu + b, a^2\sigma^2)$$

典型例题：

(1) 离散型：分布律 \longleftrightarrow 分布函数

(2) 连续型：概率密度 \longleftrightarrow 分布函数

未知参数的确定

(3) 概率计算：

$$P(x_1 < X \leq x_2) = F(x_2) - F(x_1)$$

$$P(x_1 < X < x_2) = P(x_1 \leq X \leq x_2) = P(x_1 < X \leq x_2) = \int_{x_1}^{x_2} f(x) dx$$

$$P(X \in L) = \sum_{x_k \in L} P(X = x_k) = \sum_{x_k \in L} p_k$$

(4) 分布函数法（一般先判断 $Y=g(X)$ 的值域）

N(0,1)与分位点

$$\Phi(0) = 0.5;$$

$$\Phi(x) \begin{cases} \text{查表,} & 0 \leq x \leq 3.9, \\ \approx 1, & x > 3.9, \\ = 1 - \Phi(-x), & x < 0; \\ \approx 0, & x < -3.9, \end{cases}$$

上 α 分位点: $P\{X > z_\alpha\} = \alpha$

两个公式: $\Phi(z_\alpha) = 1 - \alpha, \quad z_{1-\alpha} = -z_\alpha$

$z_{0.025}$? $\Phi(z_{0.025}) = 1 - 0.025 = 0.975 \longrightarrow z_{0.025} = 1.96$

$z_{1-0.025} = -z_{0.025} = -1.96$

第三章

二维随机变量的分布函数

性质:

$$F(x, y) = P\{X \leq x, Y \leq y\}$$

i) $F(x, y)$ 分别关于 x, y 单调非减;

ii) $F(x, -\infty) = F(-\infty, y) = F(-\infty, -\infty) = 0$

$$F(+\infty, +\infty) = 1$$

iii) $F(x, y)$ 分别关于 x, y 右连续;

iv) $\forall x_1 < x_2, y_1 < y_2,$

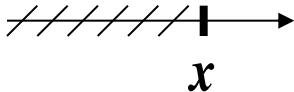
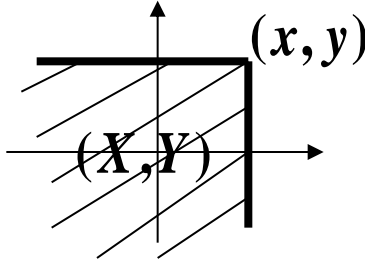
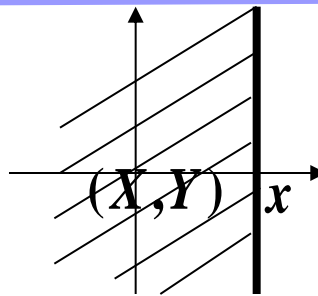
$$F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1) \geq 0$$

分布函数

离散型

连续型

计算

一维 X	二维 (X, Y)	边缘 X	关系
$F(x)$ $= P(X \leq x)$	$F(x, y)$ $= P(X \leq x, Y \leq y)$	$F_X(x) = P(X \leq x)$ $= P(X \leq x, Y < +\infty)$	$F_X(x) = \lim_{y \rightarrow +\infty} F(x, y)$
			
$F(x) = \sum_{x_k \leq x} p_k$	$F(x, y) = \sum_{\substack{x_i \leq x \\ y_j \leq y}} p_{ij}$	$F_X(x) = \sum_{x_i \leq x} \sum_{j=1}^{\infty} p_{ij}$	$P\{X = x_i\} = \sum_{j=1}^{\infty} p_{ij}$
$F(x)$ $= \int_{-\infty}^x f(t) dt$	$F(x, y)$ $= \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$	$F_X(x)$ $f_X(x)$ $= \int_{-\infty}^x \int_{-\infty}^{+\infty} f(x, y) dy dx$	$f_X(x)$ $= \int_{-\infty}^{+\infty} f(x, y) dy$
$P(x_1 < X \leq x_2) = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x) dx$		$P\{(X, Y) \in G\} = \iint_G f(x, y) dx dy$	

边缘分布: $F_X(x) = \lim_{y \rightarrow +\infty} F(x, y); F_Y(y) = \lim_{x \rightarrow +\infty} F(x, y)$

$$p_{i.} = P\{X = x_i\} = \sum_{j=1}^{\infty} p_{ij}$$

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy; f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

(注: 求边缘密度时先画出 $f(x, y)$ 的非零区域! 积分上下限可能跟另一变量有关!)

条件分布: $P(X = x_i | Y = y_j) = \frac{P_{ij}}{P_{.j}}$

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}, \text{ } f_Y(y) \neq 0 \text{ 时才有意义!}$$

概率计算
 X, Y 连续型

$$P(X \in L | Y = y) = \int_{x \in L} f_{X|Y}(x|y) dx \quad (\text{视} y \text{ 为参数})$$

一般,
条件概率

$$P(X \in L_1 | Y \in L_2) = \frac{P(X \in L_1, Y \in L_2)}{P(Y \in L_2)}$$

(L, L_1, L_2 为区间)

1. X, Y 相互独立 (定义)

$$\text{——} \quad \forall x, y \in R, \quad F(x, y) = F_X(x) F_Y(y)$$

$$\text{即} \quad P\{X \leq x, Y \leq y\} = P\{X \leq x\} P\{Y \leq y\}$$

2. X, Y 相互独立

$$\longleftrightarrow \quad \forall x_1 < x_2, y_1 < y_2,$$

$$\begin{aligned} & P\{x_1 < X \leq x_2, y_1 < Y \leq y_2\} \\ &= P\{x_1 < X \leq x_2\} P\{y_1 < Y \leq y_2\} \end{aligned}$$

3. X, Y (离散型) 相互独立

$$\longleftrightarrow \quad \forall i, j, \quad p_{ij} = p_{i\cdot} \cdot p_{\cdot j}$$

4. X, Y (连续型) 相互独立

$$\longleftrightarrow \quad f(x, y) = f_X(x) f_Y(y) \text{ 几乎处处成立。}$$

二维均匀分布

$$f(x, y) = \begin{cases} \frac{1}{\sigma}, & (x, y) \in D, \\ 0, & \text{其他.} \end{cases}$$

D —— 平面区域, σ —— D 的面积, $\sigma \neq 0$

二维指数分布 (了解)

$$f(x, y) = \begin{cases} \frac{1}{\theta^2} e^{-\frac{1}{\theta}(x+y)}, & x > 0, y > 0 \\ 0, & \text{其它} \end{cases} \quad (\theta > 0)$$

结论

$$(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$$

则 ① $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$

② X, Y 相互独立 $\longleftrightarrow \rho = 0$

结论

设 X_1, X_2, \dots, X_n 相互独立,

$$X_i \sim N(\mu_i, \sigma_i^2), \quad i = 1, 2, \dots, n$$

$$\rightarrow c_1 X_1 + c_2 X_2 + \dots + c_n X_n$$

$$\sim N\left(c_1 \mu_1 + c_2 \mu_2 + \dots + c_n \mu_n, c_1^2 \sigma_1^2 + c_2^2 \sigma_2^2 + \dots + c_n^2 \sigma_n^2\right)$$

c_1, c_2, \dots, c_n 为任意实数。

$$X \sim N(\mu, \sigma^2), \quad Y = aX + b$$

$$\rightarrow Y \sim N(a\mu + b, a^2 \sigma^2)$$

一、 $Z=X+Y$ 的分布

若 X, Y 相互独立，有如下卷积公式：

$$f_{X+Y}(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx$$

$$f_{X+Y}(z) = \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) dy$$

卷积公式用于求独立随机变量和的概率密度。

由卷积公式可以验证：

正态分布、泊松分布、伽马分布具有可加性！

二、分布函数法 —— 基本方法

应用：利用 (X, Y) 的联合密度函数 $f(x, y)$ ，求它们的函数 $g(X, Y)$ 的分布函数或概率密度函数

—— 见下页例题

例 设 (X, Y) 的密度为:


$$f(x, y) = \begin{cases} e^{-(x+y)}, & x > 0, y > 0, \\ 0, & \text{其他} \end{cases} \quad \longrightarrow f_{2X+Y}(z)$$

解: $\forall z, F_{2X+Y}(z) = P\{2X + Y \leq z\}$

$$= \iint_{2x+y \leq z} f(x, y) dx dy$$

$$= \iint_D e^{-(x+y)} dx dy$$

$$= \begin{cases} \int_0^{z/2} dx \int_0^{z-2x} e^{-(x+y)} dy = e^{-z} - 2e^{-\frac{z}{2}} + 1, & z > 0, \\ 0, & z \leq 0. \end{cases}$$



例 设 (X, Y) 的密度为:

$$f(x, y) = \begin{cases} e^{-(x+y)}, & x > 0, y > 0, \\ 0, & \text{其他} \end{cases} \xrightarrow{\text{red arrow}} f_{2X+Y}(z)$$

解:

$$F_{2X+Y}(z) = \begin{cases} e^{-z} - 2e^{-\frac{z}{2}} + 1, & z > 0, \\ 0, & z \leq 0. \end{cases}$$

$$\xrightarrow{\text{red arrow}} f_{2X+Y}(z) = \begin{cases} e^{-\frac{z}{2}} - e^{-z}, & z > 0, \\ 0, & z \leq 0. \end{cases}$$

三、最大项与最小项的分布

要点

$$\{\max(X_1, X_2, \dots, X_n) \leq z\} = \{X_1 \leq z, X_2 \leq z, \dots, X_n \leq z\}$$

$$\{\min(X_1, X_2, \dots, X_n) > z\} = \{X_1 > z, X_2 > z, \dots, X_n > z\}$$

公式

独立！ 且同分布！

$$F_{\max}(z) = F_{X_1}(z) F_{X_2}(z) \cdots F_{X_n}(z) = (F(z))^n$$

$$\begin{aligned} F_{\min}(z) &= 1 - (1 - F_{X_1}(z))(1 - F_{X_2}(z)) \cdots (1 - F_{X_n}(z)) \\ &= 1 - (1 - F(z))^n \end{aligned}$$

第四章

数学期望的计算

$$E(X) = \sum_k x_k p_k$$

$$E(g(X)) = \sum_k g(x_k) p_k$$

$$EX = \int_{-\infty}^{+\infty} x f(x) dx$$

$$E(g(X, Y)) = \sum_{i,j} g(x_i, y_j) p_{ij}$$

$$E(g(X)) = \int_{-\infty}^{+\infty} g(x) f(x) dx$$

$$EX = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f(x, y) dx dy = \int_{-\infty}^{+\infty} x f_X(x) dx$$

$$\begin{aligned} E(g(X)) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x) f(x, y) dx dy \\ &= \int_{-\infty}^{+\infty} g(x) f_X(x) dx \end{aligned}$$

$$E(g(X, Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$$

方差的计算

$$DX = E(X^2) - (EX)^2$$

X	$(0-1)$	$B(n, p)$	$\pi(\lambda)$	$U(a, b)$	$Exp(\theta)$	$N(\mu, \sigma^2)$
EX	p	np	λ	$\frac{a+b}{2}$	θ	μ
DX	$p(1-p)$	$np(1-p)$	λ	$\frac{(a-b)^2}{12}$	θ^2	σ^2

$$D(X+Y) = DX + DY + 2\text{cov}(X, Y)$$

切比雪夫不等式：设 $E(X)$, $D(X)$ 存在, 则 $\forall \varepsilon > 0$

$$P\{|X - E(X)| \geq \varepsilon\} \leq \frac{1}{\varepsilon^2} D(X)$$

等价于 $P\{|X - EX| < \varepsilon\} \geq 1 - \frac{1}{\varepsilon^2} DX$

可用于估计

协方差 $\text{cov}(X, Y) = E[(X - EX)(Y - EY)]$

相关系数 $\rho_{XY} = \frac{\text{cov}(X, Y)}{\sqrt{DX} \sqrt{DY}},$

若 $\rho_{X,Y} = 0$, 则 X, Y 不相关。

X, Y 不相关 $\iff \text{cov}(X, Y) = 0 \iff E(XY) = EX \cdot EY$
 $\iff D(X + Y) = DX + DY$

结论1

X, Y 相互独立 $\implies X, Y$ 不相关。反之不然！

结论2

当 (X, Y) 服从二维正态分布时,
 X, Y 相互独立 $\iff X, Y$ 不相关。

第五章

贝努利 大数定律

设 $X_1, X_2, \dots, X_n, \dots$ 独立同 (0-1) 分布,
则 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} p \quad (n \rightarrow \infty)$

切比雪夫 大数定律 特例

设 1) $\{X_n\}$ 为独立随机变量序列;
2) $\forall k, E(X_k) = \mu, D(X_k) = \sigma^2$
则 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu \quad (n \rightarrow \infty)$

辛钦 大数定律

设 1) $\{X_n\}$ 独立同分布;
2) $\forall k, E(X_k) = \mu$
则 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu \quad (n \rightarrow \infty)$

林德伯格—勒维中心极限定理

条件: 1) $\{X_n\}$ 独立同分布;

$$2) \forall k, E(X_k) = \mu, D(X_k) = \sigma^2, 0 < \sigma^2 < \infty$$

应用 $\sum_{k=1}^n X_k \overset{\text{近似}}{\sim} N(n\mu, n\sigma^2)$ 或 $\frac{1}{n} \sum_{k=1}^n X_k \overset{\text{近似}}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right)$

棣莫弗—拉普拉斯中心极限定理

n
较大时

条件: $X \sim B(n, p)$,

应用 $\frac{X - np}{\sqrt{np(1-p)}} \overset{\text{近似}}{\sim} N(0, 1)$

或: $X \overset{\text{近似}}{\sim} N(np, np(1-p))$

第六章 总体是个随机变量 X ,

X_1, X_2, \dots, X_n 是总体 X 的一个样本。

统计量
不含未知参数

样本 —— 独立同分布;
与总体 X 同分布;

常用统计量

样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

样本标准差

$$S = \sqrt{S^2}$$

样本 k 阶原点矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

性质 设总体 X 的期望、方差、 k 阶矩均存在,

$$\text{记 } EX = \mu, \quad DX = \sigma^2, \quad E(X^k) = \mu_k$$

则 **1)** $A_1 = \bar{X}, \quad E(\bar{X}) = \mu, \quad D\bar{X} = \frac{\sigma^2}{n}$

2) $E(A_k) = \mu_k,$

3) $E(S^2) = \sigma^2,$

了解 \rightarrow **4)** $(n-1)S^2 = nB_2$

$$= \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

四大分布: $N(\mu, \sigma^2)$ χ^2 分布 t 分布 F 分布

定理

构成! 分位点!

设总体 $X \sim N(\mu, \sigma^2)$,

X_1, X_2, \dots, X_n 是总体 X 的一个样本,

\bar{X}, S^2 是样本均值与样本方差,

则 1) $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ 即 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$

2) $\frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$

3) $\frac{(n-1)S^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)$

4) \bar{X} 与 S^2 相互独立。

第七章

(一) 点估计 1、矩估计法

总体 X 的分布中含 k 个未知参数 $\theta_1, \theta_2, \dots, \theta_k$

设 总体前 k 阶矩均存在, $E(X^l) = \mu_l(\theta_1, \theta_2, \dots, \theta_k)$
 $l = 1, 2, \dots, k$

样本前 k 阶矩为: A_1, A_2, \dots, A_k (视为已知)

令总体矩
= 样本矩
列 k 个方程:

$$\begin{cases} E(X) = A_1 \\ E(X^2) = A_2 \\ \vdots \\ E(X^k) = A_k \end{cases}$$



矩估计量为

$$\hat{\theta}_i(X_1, X_2, \dots, X_n)$$

矩估计值为

$$\hat{\theta}_i(x_1, x_2, \dots, x_n)$$

$$i = 1, 2, \dots, k$$

2、极大似然估计法

X_1, X_2, \dots, X_n 是总体 X 的一个样本,

(1) 离散型 x_1, x_2, \dots, x_n 为样本值。

总体 X 的分布律: $P\{X = x\} = p(x; \theta)$, $\theta \in \Theta$, θ 未知,

则 $L(\theta) = \prod_{i=1}^n p(x_i; \theta)$ 为样本的似然函数。

(2) 连续型 总体 X 的概率密度: $f(x; \theta)$, $\theta \in \Theta$, θ 未知,

似然函数为 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$

$$\text{令 } \frac{d}{d\theta} \ln L(\theta) = 0 \quad \theta \in \Theta$$

解得 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 极大似然估计值;

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 极大似然估计量;

若令导数等于0
不能得到 $L(\theta)$
最大值, 则根据
 $L(\theta)$ 单调性找最
大值点——
(教材P194例2)

(二) 统计量的评选标准 (优良性)

1、无偏性

设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的估计量, $E(\hat{\theta})$ 存在,
 $\hat{\theta}$ 为 θ 的**无偏估计量** —— $E(\hat{\theta}) = \theta$

2、有效性

设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 均为 θ 的无偏估计量,

$\hat{\theta}_1$ 较 $\hat{\theta}_2$ **更有效** —— $D(\hat{\theta}_1) < D(\hat{\theta}_2)$

3、相合性

设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的估计量,

$\hat{\theta}$ 为 θ 的**相合估计量** —— $\hat{\theta} \xrightarrow{P} \theta (n \rightarrow \infty)$

结论

无论总体 X 服从何种分布，总有

- 1) \bar{X} 是 $\mu(EX)$ 的无偏估计量;
- 2) A_k 是 $\mu_k(EX^k)$ 的无偏估计量;
- 3) A_k 是 $\mu_k(EX^k)$ 的相合估计量;
- 4) S^2 是 $\sigma^2(DX)$ 的无偏估计量;
- 5) B_2 是 $\sigma^2(DX)$ 的有偏估计量;

(三) 一个正态总体的区间估计

求置信区间的步骤

$1-\alpha$ —— 置信度;

1) 找一个样本的函数 $W = W(X_1, X_2, \dots, X_n; \theta)$

满足: 含 θ

除 θ 以外不含其它未知参数

W 分布确定

2) 由给定的 α 及分位点定义, 确定 a, b 使

$$P\{a < W < b\} = 1 - \alpha$$

3) $a < W(X_1, X_2, \dots, X_n; \theta) < b \longrightarrow \underline{\theta} < \theta < \bar{\theta} \longrightarrow (\underline{\theta}, \bar{\theta})$

未知参数	模型	置信区间
$\mu (\sigma^2 \text{已知})$	$\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0,1)$	$\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\frac{\alpha}{2}} \right)$
$\mu (\sigma^2 \text{未知})$	$\frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$	$\left(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\frac{\alpha}{2}}(n-1) \right)$
σ^2	$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$	$\left(\frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)} \right)$
σ	$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$	$\left(\sqrt{\frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}}, \sqrt{\frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}} \right)$

第八章

假设检验解题步骤

1) 对总体提出假设;

H_0 原假设

H_1 备择假设

2) 寻找适合当前问题的检验统计量;

满足: 它的观察值可量化数据与 H_0 的差异;

H_0 为真时, 有确定分布;

3) 由给定的 α 及分位点定义确定 H_0 的拒绝域 C

4) 取样判断: 若观察值 $\in C$, 则拒绝 H_0
否则接受 H_0

一个正态总体的参数假设检验

① σ^2 已知时, 对 μ 的检验—— U 检验法

检验统计量 $U = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$

H_0 真时, $U \sim N(0,1)$

H_0	H_1	C
$\mu = \mu_0$	$\mu \neq \mu_0$ (双)	$\left(-\infty, -z_{\frac{\alpha}{2}}\right) \cup \left(z_{\frac{\alpha}{2}}, +\infty\right)$
$\mu = \mu_0$	$\mu > \mu_0$ (右)	$(z_{\alpha}, +\infty)$
$\mu = \mu_0$	$\mu < \mu_0$ (左)	$(-\infty, -z_{\alpha})$

2 σ^2 未知时, 对 μ 的检验—— t 检验法

检验统计量 $t = \frac{\bar{X} - \mu_0}{S / \sqrt{n}}$

H_0 真时, $t \sim t(n-1)$

H_0	H_1	C
$\mu = \mu_0$	$\mu \neq \mu_0$ (双)	$\left(-\infty, -t_{\frac{\alpha}{2}}(n-1)\right) \cup \left(t_{\frac{\alpha}{2}}(n-1), +\infty\right)$
$\mu = \mu_0$	$\mu > \mu_0$ (右)	$\left(t_{\alpha}(n-1), +\infty\right)$
$\mu = \mu_0$	$\mu < \mu_0$ (左)	$\left(-\infty, -t_{\alpha}(n-1)\right)$

说明

① $H_0 : \mu \geq \mu_0$ $H_1 : \mu < \mu_0$ 单边假设检验

② $H_0 : \mu = \mu_0$ $H_1 : \mu < \mu_0$

两者的拒绝域相同。

③ $H_0 : \mu \leq \mu_0$ $H_1 : \mu > \mu_0$ 单边假设检验

④ $H_0 : \mu = \mu_0$ $H_1 : \mu > \mu_0$

两者的拒绝域相同。

注：对 σ^2 的单边检验类似。

3 对 σ^2 的检验 —— χ^2 检验法

检验统计量 $\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$ H_0 真时, $\chi^2 \sim \chi^2(n-1)$

H_0	H_1	C
$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$ (双)	$\left(0, \chi_{1-\frac{\alpha}{2}}^2(n-1)\right) \cup \left(\chi_{\frac{\alpha}{2}}^2(n-1), +\infty\right)$
$\sigma^2 = \sigma_0^2$	$\sigma^2 > \sigma_0^2$ (右)	$\left(\chi_{\alpha}^2(n-1), +\infty\right)$
$\sigma^2 = \sigma_0^2$	$\sigma^2 < \sigma_0^2$ (左)	$\left(0, \chi_{1-\alpha}^2(n-1)\right)$

考试安排与要求

考试：2016年1月13日周三上午8:30 – 10:30

答疑：2016年1月12日周二上午9:00 – 11:00

(理化楼308, 6+9)

2016年1月12日周二下午2:00 – 4:00

(理化楼308, 7+10)


题型：填空，选择，计算，证明

两个正态总体的区间估计和假设检验不考！

没讲的不考！

考试安排与要求

- 1、考试时请关闭手机，
考试期间打开手机视为作弊！
- 2、发卷后首先检验试卷质量、页数、题数；
不得拆散装订好的试卷！
- 3、正确填写学院、班级、姓名等个人信息，
空填、错填或涂改个人信息视为无效试卷！
- 4、不能带计算器！
- 5、草稿纸不收。



谢谢大家！

希望每个同学都能取得
满意的成绩！